Real-World Reinforcement Learning of Active Perception Behaviors

Asymmetric Advantage Weighted Regression **(AAWR)**

Как научить робота **искать недостающую информацию**, когда текущая камера видит не всё важное для действия

Hu et al., NeurIPS 2025 / arXiv:2512.01188 / official code: penn-pal-lab/aawr

Актуальность в контексте прошлых семинаров

Логическая цепочка

1. **Dreamer**: агент учится в латентной модели мира.
2. **DreamVLA**: модель предсказывает полезное визуальное будущее и генерирует chunk действий.
3. **Plan2Explore**: агент собирает опыт там, где модель не уверена.

Новый шаг

$$\text{novelty} \rightarrow \text{task-relevant information}$$

Главная мысль AAWR

Робот должен исследовать не всё неизвестное, а именно то, что **повышает шанс выполнить конкретную задачу**.

Камера видит не всё, что нужно для действия

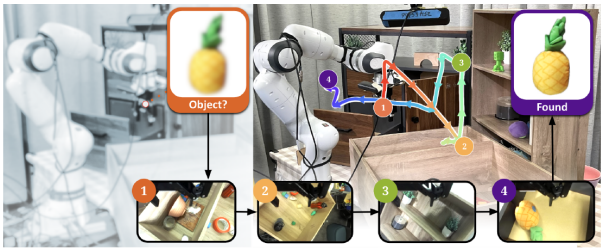


Figure 1 из статьи: robot ищет объект в сильно окклюзированной сцене.

Почему это сложно

- объект может быть закрыт другими объектами;
- один wrist-frame часто не содержит ответа;
- нужно сначала выбрать **информационное действие**;
- только потом выполнять grasp / handoff.

Смысл: сначала получить недостающий ракурс, затем делать grasp / handoff.

Что именно называется active perception здесь

Пассивное восприятие

- policy получает текущий кадр;
- сразу выбирает действие;
- если объекта не видно, решение часто случайное.

Активное восприятие

- policy двигает сенсор или сам объект;
- получает новую информацию;
- затем передаёт управление grasp policy или продолжает задачу.

act to know $\Rightarrow$ act to succeed

Формализация: POMDP

$$(\mathcal{S}, \mathcal{A}, \mathcal{O}, T, R, E, P, \gamma)$$

- $s_t \in \mathcal{S}$ - полное состояние среды;
- $o_t \in \mathcal{O}$ - частичное наблюдение;
- $a_t \in \mathcal{A}$ - действие;
- $R(r_t \mid s_t, a_t)$ - награда;
- $E(o_t \mid s_t)$ - модель наблюдения.

Пример

Полное состояние знает, где лежит объект. Wrist-camera может видеть только край полки или закрытый ящик.

Почему не MDP

Оптимальное действие зависит не только от текущего кадра, но и от истории: где робот уже смотрел и что не нашёл.

Agent state: как policy получает историю

$$h_t = (o_0, a_0, o_1, a_1, \dots, o_t),$$
$$z_t = f(h_t),$$
$$\pi = \pi(a_t \mid z_t).$$

- h_t — вся накопленная история наблюдений и действий;
- z_t — компактное состояние агента после encoder/RNN;
- на роботе policy действует только по z_t.

Эквивалентный MDP

Для анализа удобно считать состоянием пару:

$$(s_t, z_t)$$

где s_t — скрытая правда о мире, а z_t — то, что знает агент.

Ключевой конфликт: critic может знать больше, чем policy.

Мысль 1: сначала учимся копировать действия

Behavior Cloning как база

$$\mathcal{D} = \{(z_i, a_i)\}_{i=1}^{N}$$

- z_i — что видел агент;
- a_i — действие из демонстрации / replay buffer;
- policy учится восстанавливать действие по наблюдению.

Обычная supervised-задача

$$\max_{\pi} \mathbb{E}_{(z,a)\sim\mathcal{D}} [\log \pi(a \mid z)]$$

Почему этого мало

BC не различает хорошие, лишние и ошибочные действия — все они копируются одинаково.

«увидел $z \to$ повтори a», но без оценки качества действия.

Мысль 2: копируем хорошие действия сильнее

Weighted BC

Оставляем supervised-обучение policy, но каждому примеру даём вес:

$$\max_{\pi} \mathbb{E}\left[w \log \pi(a \mid z)\right]$$

- большой w — пример сильно двигает policy;
- малый w — пример почти не влияет.

Откуда берётся вес

Critic оценивает, было ли действие лучше среднего:

$$A^{\mu} = Q^{\mu} - V^{\mu}$$

$$w = \exp\left(\frac{A^{\mu}}{\beta}\right)$$

Как из этого получается AAWR

Берём BC из мысли 1, добавляем advantage-веса из мысли 2, а critic делаем асимметричным: он видит privileged state (s, z), тогда как policy видит только z.

Почему обычный AWR ломается в POMDP

Symmetric AWR

$$\hat{A}(z,a) = \hat{Q}(z,a) - \hat{V}(z)$$

Critic и policy видят только частичное состояние z.

Проблема

Одинаковый z может соответствовать разным скрытым состояниям s.

- в одном случае действие полезно;
- в другом — вредно;
- critic усредняет разные миры.

Математически

$$\exp\left(\frac{\mathbb{E}[A \mid z,a]}{\beta}\right) \neq \mathbb{E}\left[\exp\left(\frac{A}{\beta}\right)\middle| z,a\right]$$

Раннее усреднение по скрытому s теряет информацию о том, какое действие реально было лучше.

Главная идея AAWR: асимметричное обучение

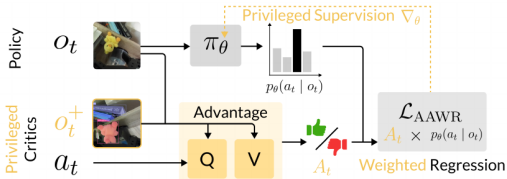


Figure 2 из статьи: policy получает частичное наблюдение; Q,V получают privileged observations.

Разделение ролей

- **policy**: видит только z_t;
- **critic**: во время обучения видит (s_t, z_t);
- advantage становится более точным;
- в inference privileged-сенсоры не нужны.

Ключевая формула Asymmetric Advantage Weighted Regression (AAWR).

Asymmetric AWR objective

$$\mathcal{J}_{\text{AAWR}}(\pi) = \mathbb{E}_{(s,z)\sim d_\mu,\ a\sim\mu(a|z)} \left[\underbrace{\exp\left(\frac{A^\mu(s,z,a)}{\beta}\right)}_{\text{вес от critic}} \underbrace{\log \pi(a \mid z)}_{\text{копирование policy}} \right].$$

Матожидание

Берём пары (s, z) из распределения посещений d_μ и действия a из behavior policy μ.

Advantage

$$A^\mu(s,z,a) = Q^\mu(s,z,a) - V^\mu(s,z)$$

$A > 0$ — копируем сильнее,
$A < 0$ — копируем слабее.

Откуда берётся экспонента и β

Policy improvement с KL-ограничением

$$\max_{\pi} \mathbb{E}[A^{\mu}(s,z,a)] \qquad \text{s.t.} \quad \mathbb{E}\big[\mathrm{KL}(\pi(\cdot \mid z) \| \mu(\cdot \mid z))\big] \le \varepsilon$$

$$\pi^{*}(a \mid z) \propto \mu(a \mid z) \exp\left(\frac{A^{\mu}(s,z,a)}{\beta}\right)$$

Что означает каждый элемент

- экспонента появляется из KL-ограниченного улучшения policy;
- β — temperature / множитель Лагранжа: управляет резкостью весов;
- меньше β — сильнее доверяем critic; больше β — ближе к обычному BC;
- умножение на $\log \pi$ превращает это в weighted behavior cloning.

Как обучаются Q и V

Q-function

$$\mathcal{L}_Q = (r + \gamma V(s', z') - Q(s, z, a))^2$$

Q оценивает действие с privileged information.

Value-function

$$\mathcal{L}_V = L_2^\tau (Q(s, z, a) - V(s, z))$$

Expectile regression связывает подход с offline RL / IQL-логикой.

Зачем это нужно

Critic учится по более информативному состоянию, поэтому веса для policy становятся менее шумными.

Эксперименты: 8 задач с разной частичной наблюдаемостью

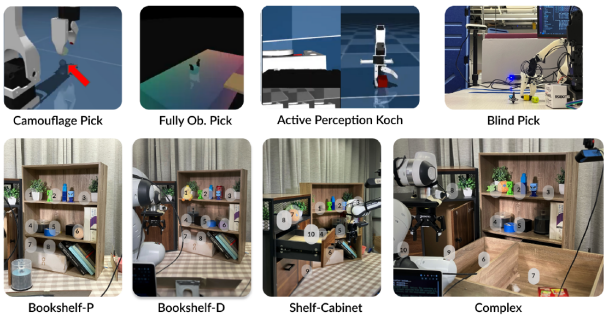


Figure 4: simulated и real-world задачи, разные роботы и сенсоры.

Проверяется

- работает ли AAWR в симуляции и на реальных роботах;
- лучше ли он BC и AWR;
- помогает ли privileged critic при ограниченных наблюдениях;
- можно ли handoff к generalist policy.

Симуляция: AAWR учится быстрее и стабильнее

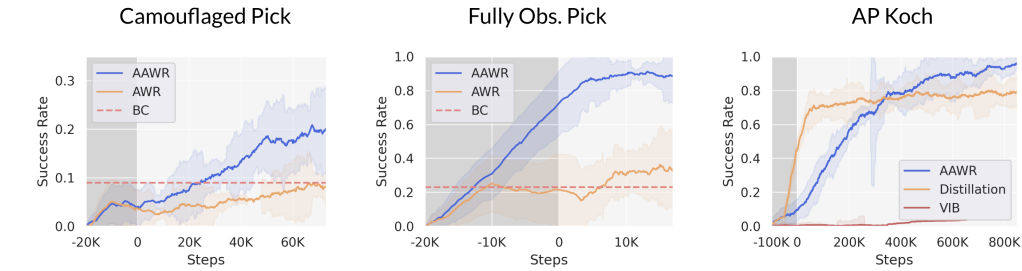


Figure 5: кривые success rate в simulated experiments.

Что видно

- AAWR обгоняет BC и AWR; выигрыш особенно заметен при partial observability.
- Преимущество не в «магии policy», а в более точной оценке advantage через privileged critic.

Real robot: search, completion, steps

Method	Bookshelf-P			Bookshelf-D			Shelf-Cabinet			Complex		
	Search ↑	Completion ↑	Steps ↓	Search ↑	Completion ↑	Steps ↓	Search ↑	Completion ↑	Steps ↓	Search ↑	Completion ↑	Steps ↓
AAWR	**92.4**	**44.4**	36.6	81.3	**44.4**	26.9	**78.2**	40.0	46.3	73.2	**50.0**	**43.0**
AWR	79.6	0.0	**34.0**	62.6	16.7	30.2	52.3	10.0	**38.0**	33.2	40.0	67.0
BC	29.9	20.0	84.0	47.7	16.7	**22.5**	28.1	15.0	125.0	31.5	15.0	77.0
π_0	11.0	16.7	263.3	66.7	33.3	229.7	10.0	10.0	280.0	29.6	20.0	252.5
Exhaustive	64.2	44.0	105.4	**96.0**	22.2	106.7	52.8	**45.0**	183.0	**78.2**	30.0	297.0
VLM+π_0	31.4	27.8	322.3	33.2	16.7	281.8	28.2	15.0	382.0	14.8	10.0	374.7

Table 3: handoff-задачи на real Franka.

Метрики и вывод

- **Search**: target найден и зафиксирован; **Completion**: generalist policy успешно завершила grasp; **Steps**: число шагов.
- AAWR чаще приводит объект в поле зрения и чаще доводит задачу до завершения после handoff.

Качественно: AAWR ищет, AWR теряет объект



Figure 6: cabinet shelf rollout. Верхняя строка — AAWR, нижняя — AWR.

Интерпретация

- AAWR исследует шкаф, находит target object и удерживает полезный ракурс.
- AWR видит небольшой фрагмент объекта, но уходит в сторону и теряет информацию.
- Главное: **сначала посмотреть лучше, затем сделать лучше**.

Код и второй этап: что планируется воспроизвести

Минимальный план

1. поднять официальный repo;
2. запустить toy/sim задачу;
3. сравнить BC, AWR, AAWR;
4. сохранить success curves и rollout video.

Абляция

clean / noisy / zero privileged state.

Типовой запуск

```
git clone https://github.com/penn-pal-lab/aawr
cd aawr
conda env create -f environment.yaml
conda activate aawr

python src/train_il.py \
  --config-name config \
  method=aawr \
  env=PrivilegedXarmLift-v0
```

На что смотреть на втором этапе

success rate, reward, episode length, stability по seed, отличие privileged critic от non-privileged critic.

Ограничения и открытый вопрос

Ограничения

- privileged information нужна хотя бы во время обучения;
- real-robot setup сложно полностью повторить;
- helper policy и grasp policy часто разделены;
- качество критика напрямую влияет на веса действий.

Что интересно дальше

- добавить окклюзии в sim-задачу;
- проверить noisy / zero privileged state;
- сравнить BC, AWR и AAWR по нескольким seed;
- подумать, как встроить идею в VLA-policy.

Главный исследовательский вопрос

Можно ли научить одну policy одновременно искать информацию и выполнять манипуляцию, без отдельной handoff-схемы?

Главный takeaway

$$\text{AAWR} = \text{AWR} + \text{privileged critic}$$

- policy остаётся deployable: использует только обычные сенсоры;
- critic при обучении получает больше информации;
- advantage становится точнее;
- робот учится информационным действиям.

Почему это хорошая тема

Статья связывает POMDP, offline RL, privileged learning и практическое active perception в робототехнике.

Вопрос на обсуждение

Можно ли встроить AAWR не как helper policy, а внутрь единой end-to-end VLA-policy?

Hu et al. Real-World Reinforcement Learning of Active Perception Behaviors. NeurIPS 2025.